

WYKŁAD 2

UCZENIE MASZYNOWE



CIESZYMY SIĘ, ŻE JESTEŚCIE Z NAMI!

Nawiązanie do wykładu 1

ML workflow

1. Definicja problemu
2. Zebranie i przygotowanie danych
3. Podział na zbiór treningowy / testowy
4. Wybór modelu
5. Trenowanie modelu
6. Ewaluacja (np. accuracy, RMSE)
7. Interpretacja wyników i wdrożenie

Sztuczna inteligencja

programy lub systemy komputerowe
symulujące ludzkie myślenie

Czy to sztuczna inteligencja?

```
let a = 10,  
    b = 20;  
  
if (a > b) {  
    console.log('a is greater than b');  
} else if (a < b) {  
    console.log('a is less than b');  
} else {  
    console.log('a is equal to b');  
}
```

Czy to sztuczna inteligencja?

```
let a = 10,  
    b = 20;  
  
if (a > b) {  
    console.log('a is greater than b');  
} else if (a < b) {  
    console.log('a is less than b');  
} else {  
    console.log('a is equal to b');  
}
```

imo
może
być

Czy to sztuczna inteligencja?

Prompt Engineering



Czy to sztuczna inteligencja?

Prompt Engineering



taaaaak

Czy to sztuczna inteligencja?

```
: # --- Analiza zależności ceny biletu (Fare) vs przeżycie na uzupełnionych danych ---  
print("\n--- Analiza zależności ceny biletu (Fare) vs przeżycie ---")
```

Czy to sztuczna inteligencja?

```
: # --- Analiza zależności ceny biletu (Fare) vs przeżycie na uzupełnionych danych ---  
print("\n--- Analiza zależności ceny biletu (Fare) vs przeżycie ---")
```

bro nikt tak nie pisze



Sztuczna inteligencja



The diagram consists of two nested ellipses. The outer ellipse is light orange and labeled "Sztuczna inteligencja". The inner ellipse is light blue and labeled "Uczenie maszynowe". Inside the blue ellipse, there is descriptive text about machine learning.

Sztuczna inteligencja

Uczenie maszynowe

programy uczące się, czyli poprawiające
działanie na zadaniu według metryki wraz
ze zdobywaniem doświadczenia

The diagram consists of two nested ovals. The outer oval is light orange and labeled 'Sztuczna inteligencja'. The inner oval is light blue and labeled 'Uczenie maszynowe'. Inside the blue oval, there is a block of text describing what machine learning is.

Sztuczna inteligencja

Uczenie maszynowe

programy uczące się, czyli poprawiające
działanie na **zadaniu** według **metryki** wraz
ze zdobywaniem **doświadczenia**

Czy to uczenie maszynowe?

Prompt Engineering



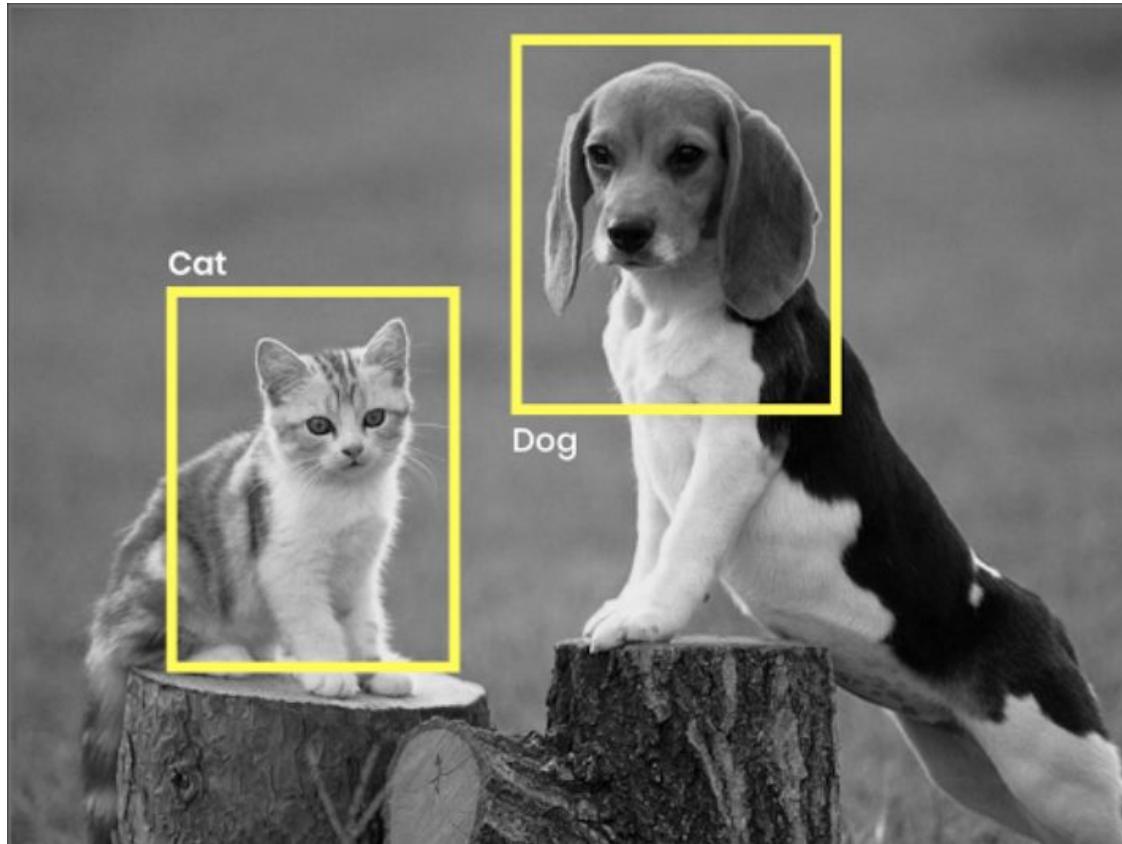
Czy to uczenie maszynowe?

Prompt Engineering



nie, poprawa działania nie jest na podstawie
doświadczenia zbieranego przez program

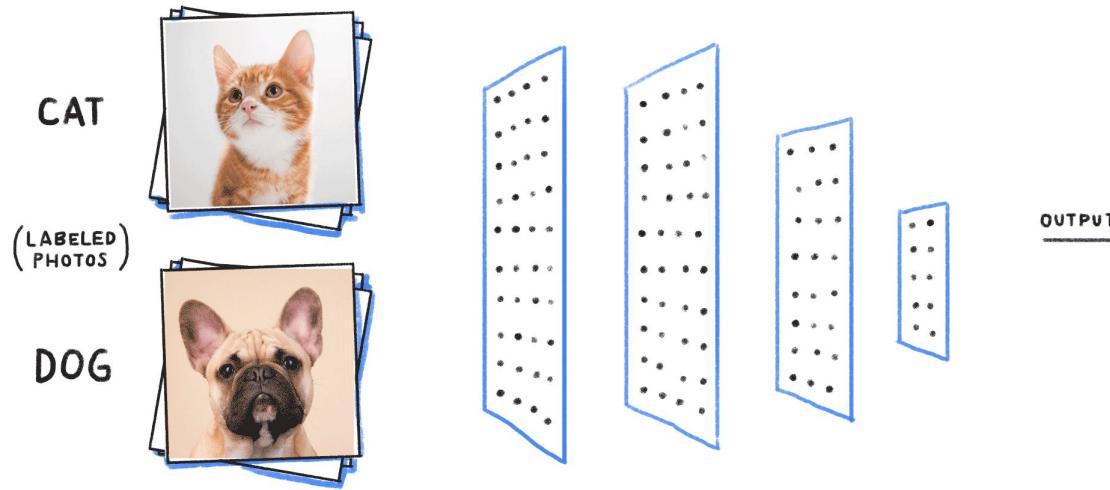
Czy to uczenie maszynowe?



Czy to uczenie maszynowe?



Czy to uczenie maszynowe?

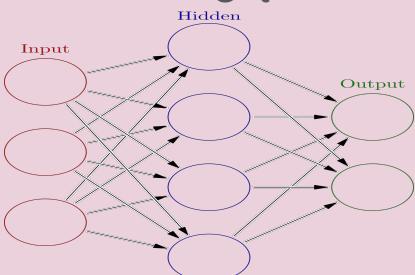


taaaaak! bo sieć się uczy

Sztuczna inteligencja

Uczenie maszynowe

Uczenie głębokie



Rodzaje ML

Uczenie
nadzorowane

Uczenie
nienadzorowane

Uczenie ze
wzmocnieniem

Rodzaje ML

**Uczenie
nadzorowane**

Uczenie
nienadzorowane

Uczenie ze
wzmocnieniem

Klasyfikacja

Uczenie
nadzorowane

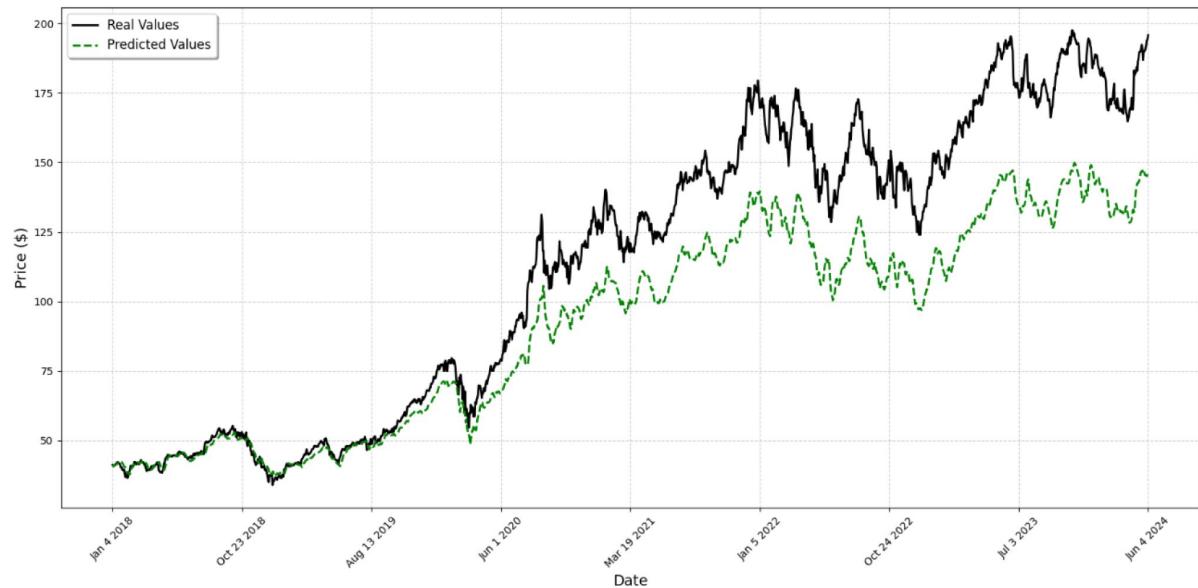
Survived -
True or False



Regresja

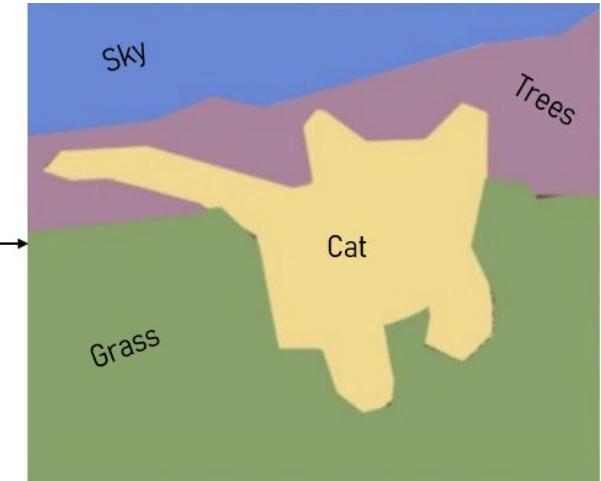
Wartość akcji

Uczanie
nadzorowane



Segmentacja semantyczna

Uczenie
nadzorowane



Rodzaje ML

Uczenie
nadzorowane

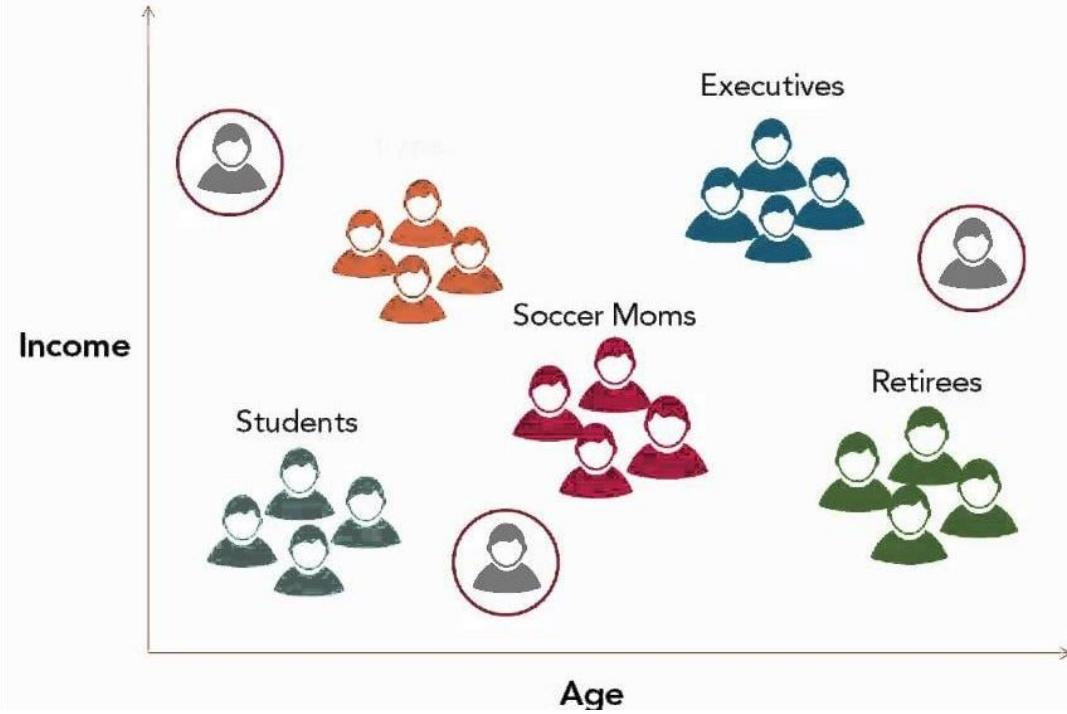
**Uczenie
nienadzorowane**

Uczenie ze
wzmocnieniem

Klasteryzacja (grupowanie)



**Uczenie
nienadzorowane**



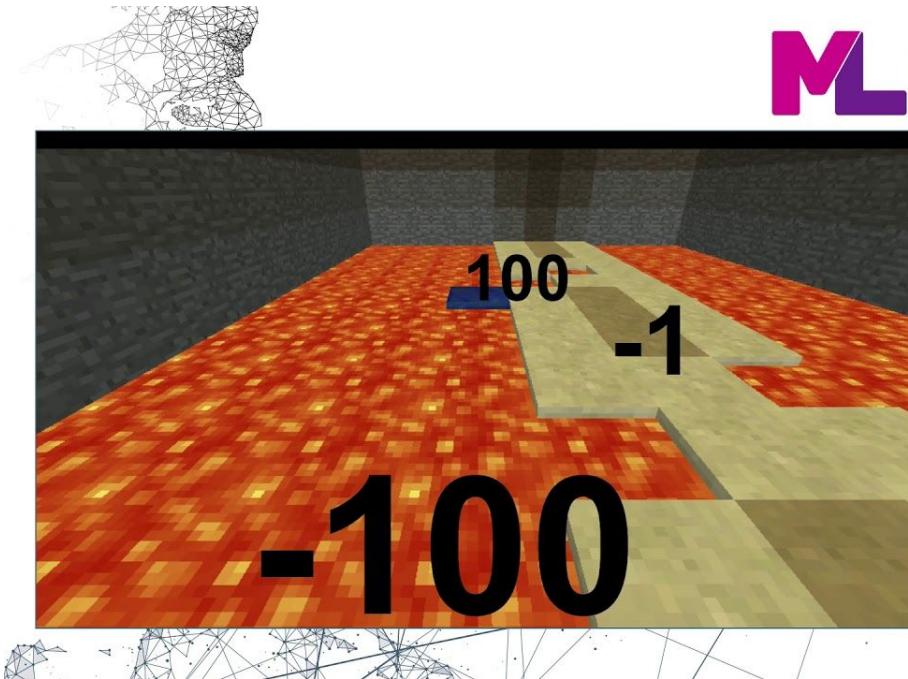
Rodzaje ML

Uczenie
nadzorowane

Uczenie
nienadzorowane

**Uczenie ze
wzmocnieniem**

Uczenie ze wzmocnieniem



ML CONFERENCE

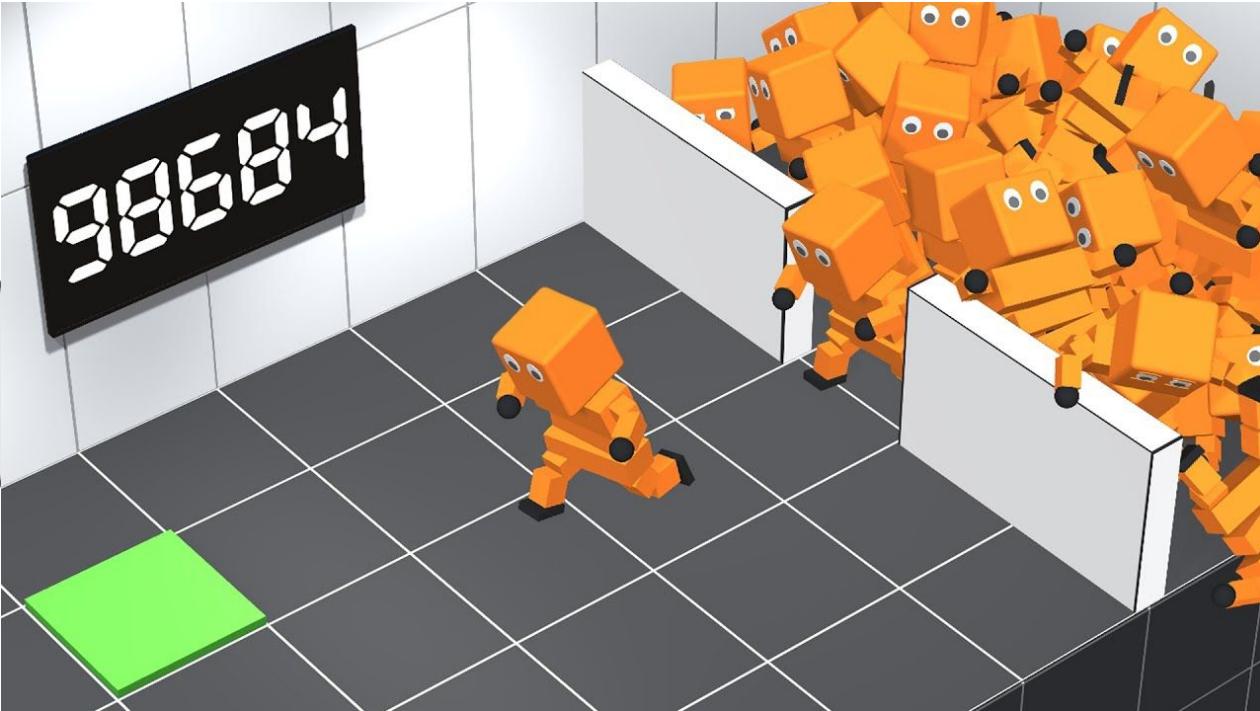
Reinforcement
Learning and
Minecraft

Lars Gregori
SAP Customer
Experience



<https://gymnasium.farama.org>

Uczenie ze wzmocnieniem



<https://gymnasium.farama.org>

Rodzaje ML

**Uczenie
nadzorowane**

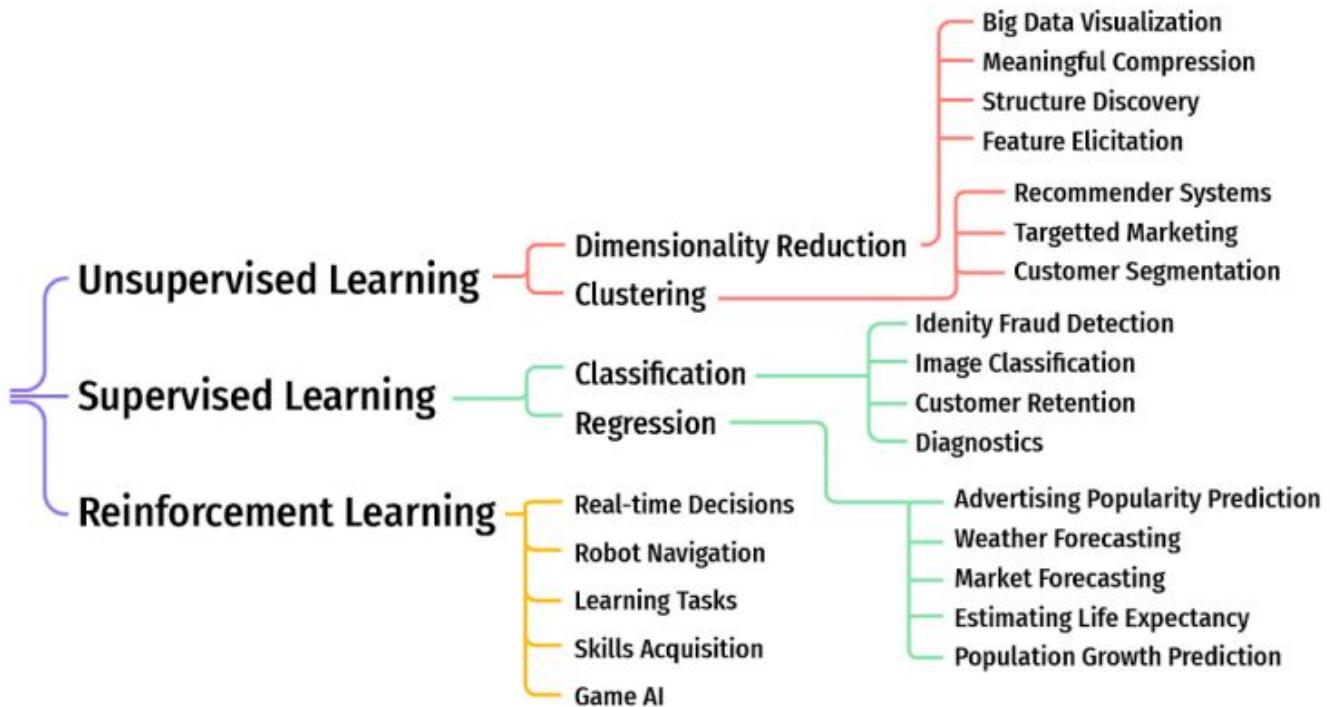
Uczenie
nienadzorowane

Uczenie ze
wzmocnieniem

Uczenie
częściowo
nadzorowane

Uczenie
samonadzorowane

Zadania ML



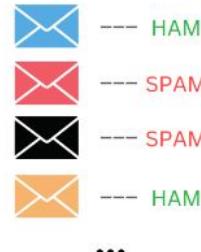
Klasyfikacja

Scenariusz: manualna anotacja

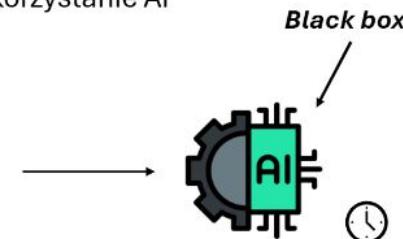


Amazon <unexercisable@df5d5.fpawms.us>
To me ↗
Hope you are doing well. I'm writing to you because we want to know if you had a bad experience with our services during the last time you visited us.
Amazon recognizes the impact of any bad situation in our community. You are worthy member of Amazon community and we will continue to work on improving our services by giving convenience and top notch technology. We are obligated to take steps to protect our beloved customers.
Like our way of saying sorry, please accept this [complementary voucher worth 50 GBP](#).
CLAIM HERE

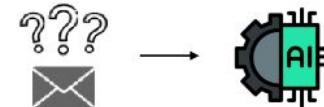
Scenariusz: wykorzystanie AI



Etykietowane dane



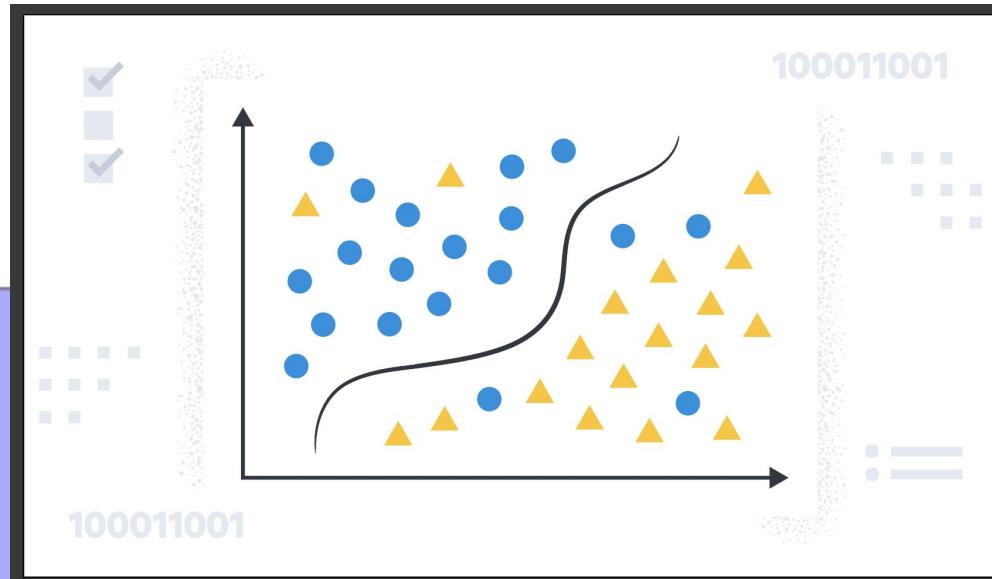
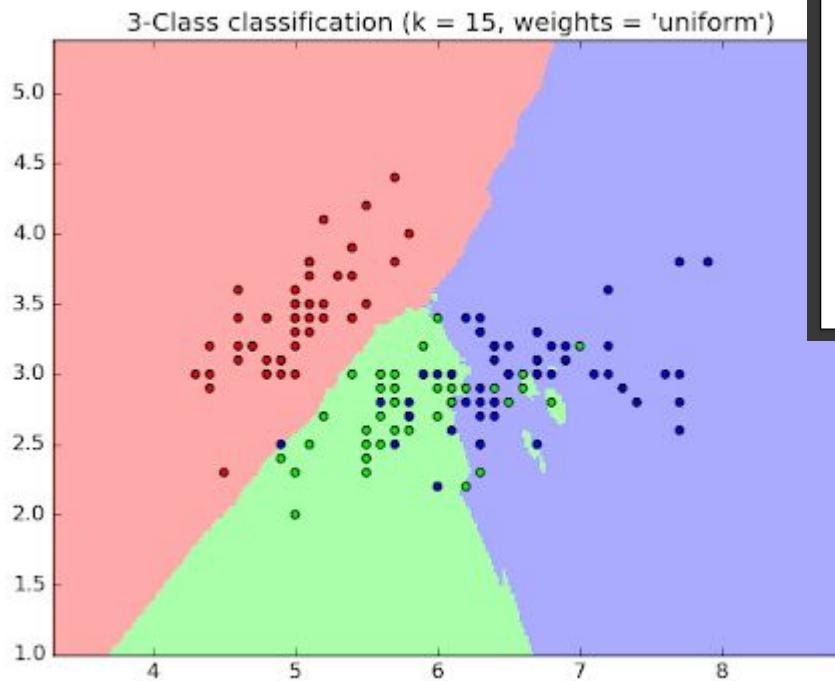
Trenowanie klasyfikatora



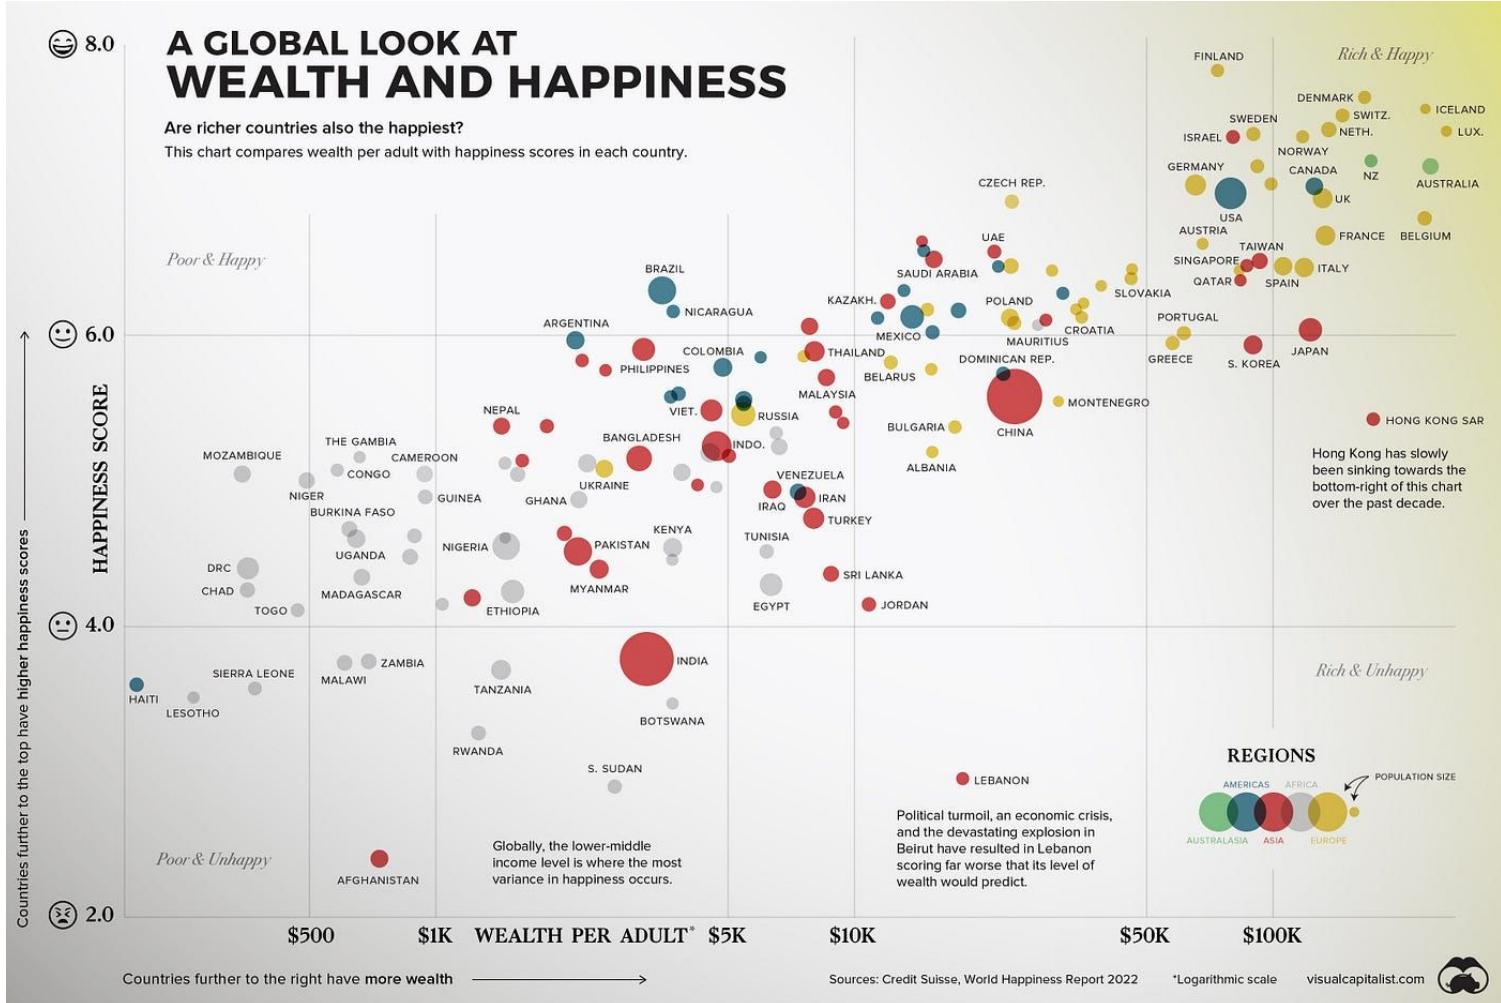
Niewidziana próbka

Predykcja dla nowego maila

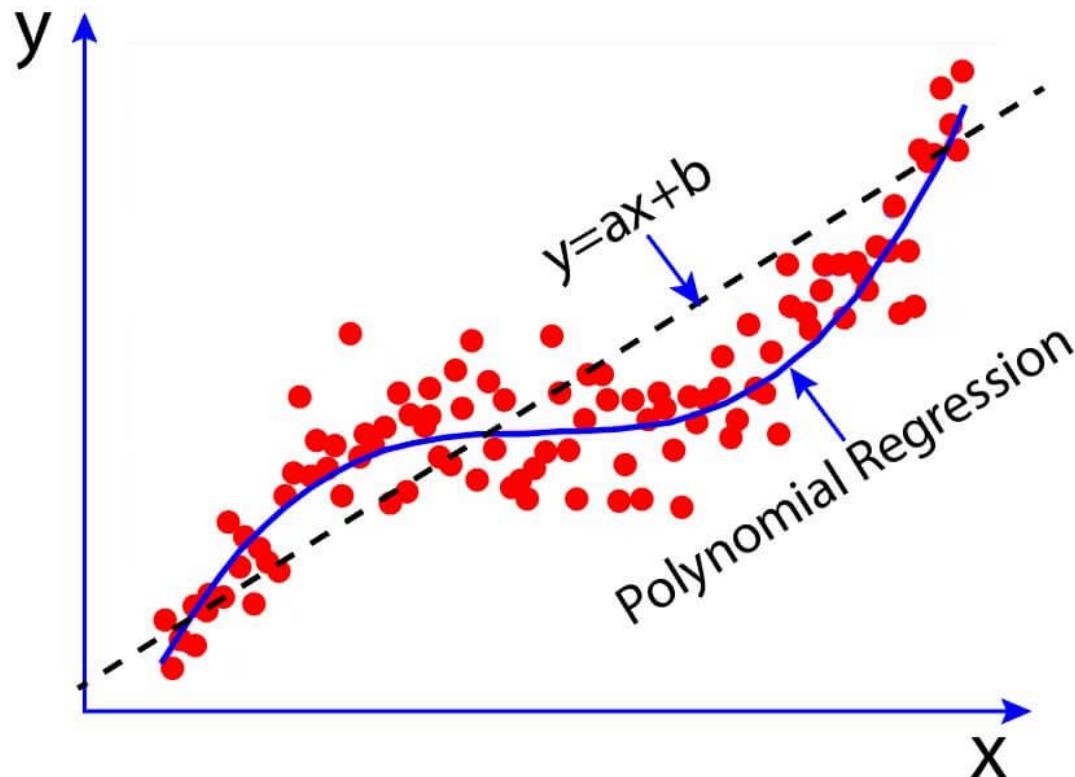
Klasyfikacja



Regresja

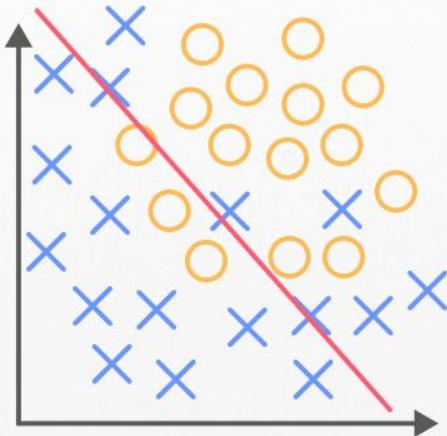


Regresja

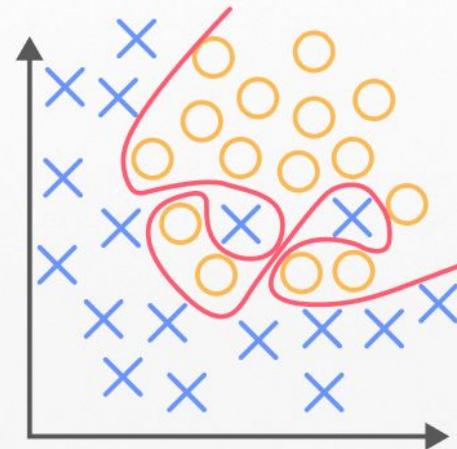


ML workflow

1. Definicja problemu
2. Zebranie i przygotowanie danych
3. Podział na zbiór treningowy / testowy
4. Wybór modelu
5. Trenowanie modelu
6. Ewaluacja (np. accuracy, RMSE)
7. Interpretacja wyników i wdrożenie



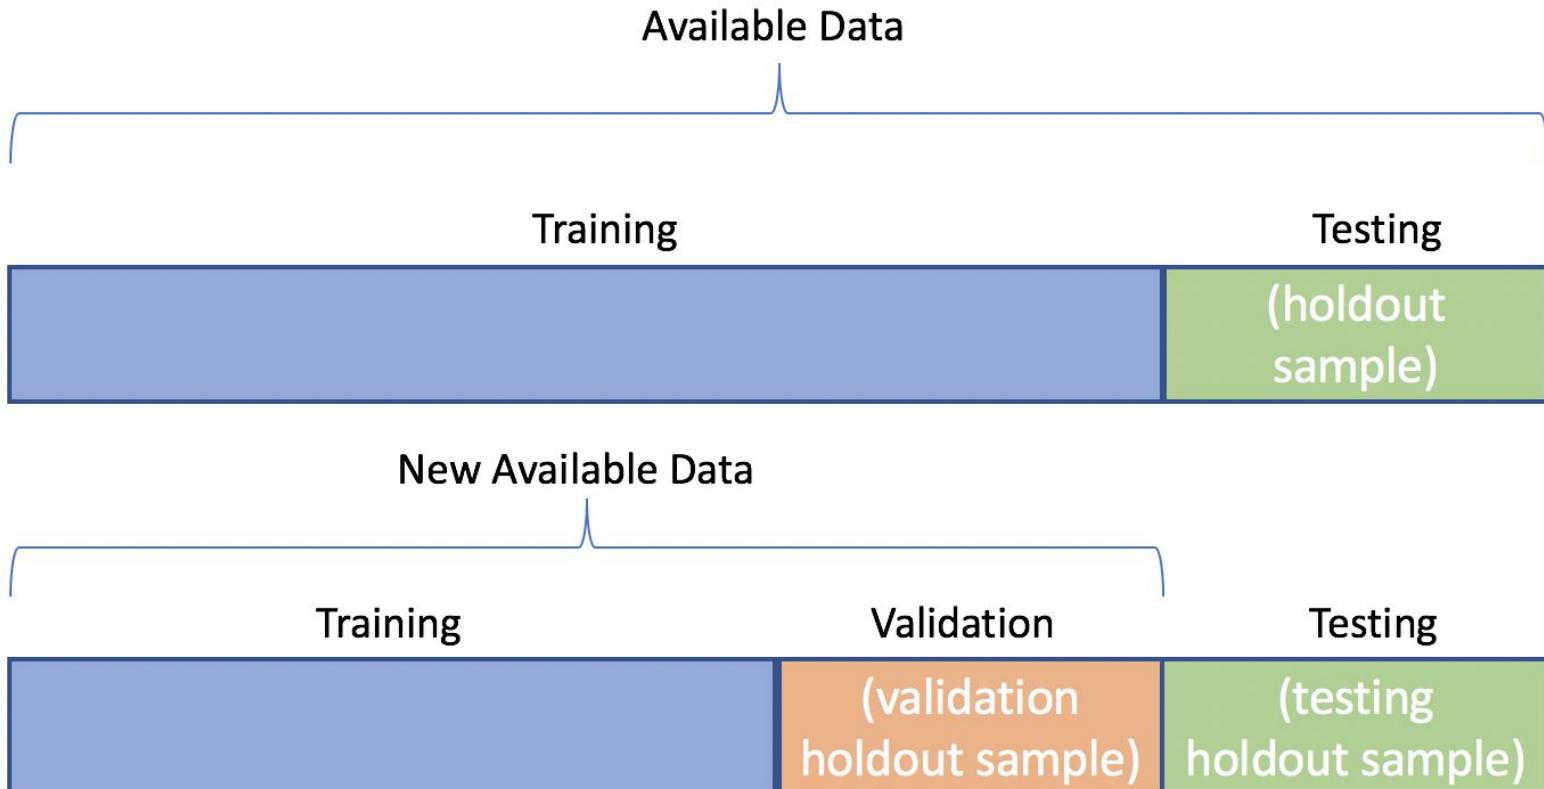
Underfitting



Overfitting

Podział na dane

wyciek danych



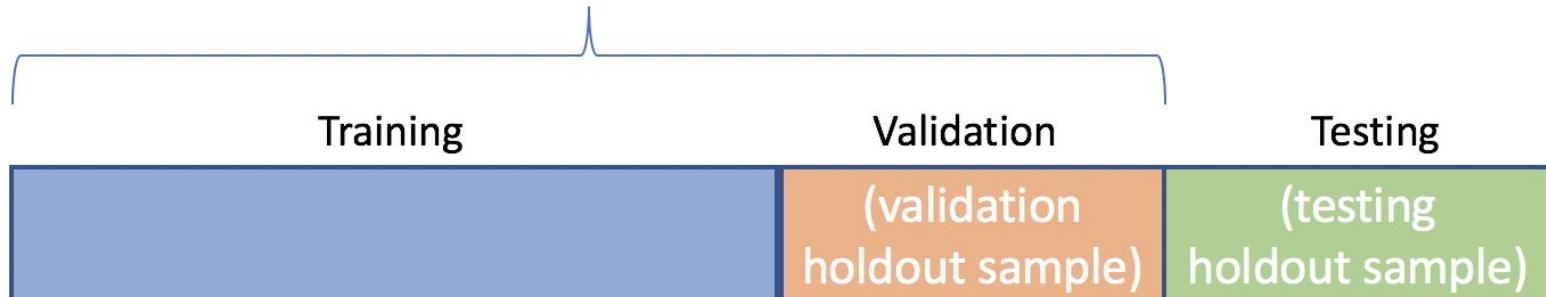
Podział na dane

wyciek danych

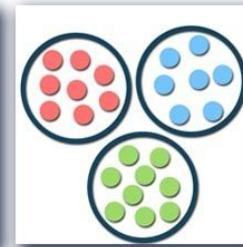
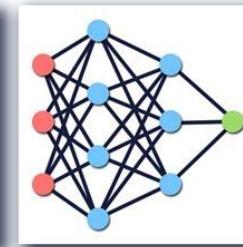
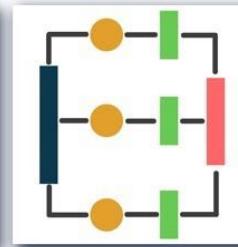
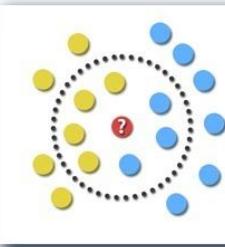
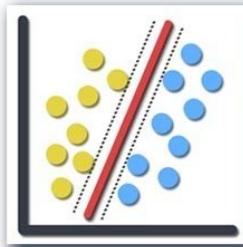
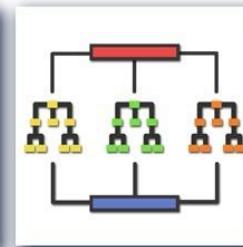
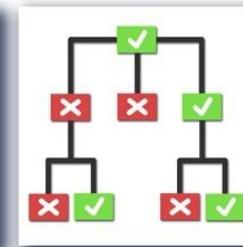
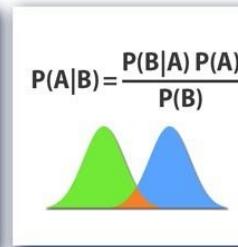
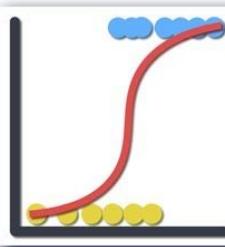
Available Data

train_test_split

```
sklearn.model_selection.train_test_split(*arrays, test_size=None, train_size=None,  
random_state=None, shuffle=True, stratify=None) [source]
```

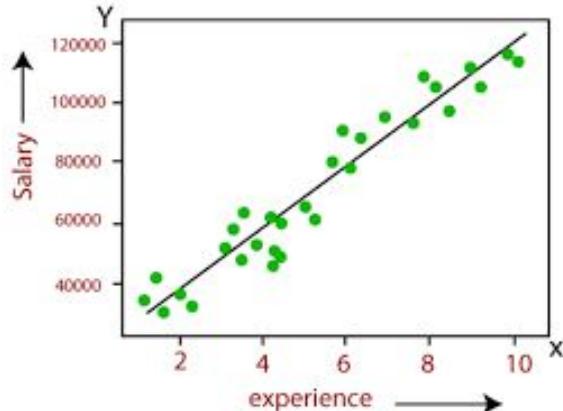


Modele ML



Regresja liniowa

- **Model:** prosta linia
- **Cel:** dopasować linię, która minimalizuje błąd (np. MSE)
- Używana do przewidywania wartości liczbowych



$$\hat{Y}_i = b_0 + b_1 X_i$$

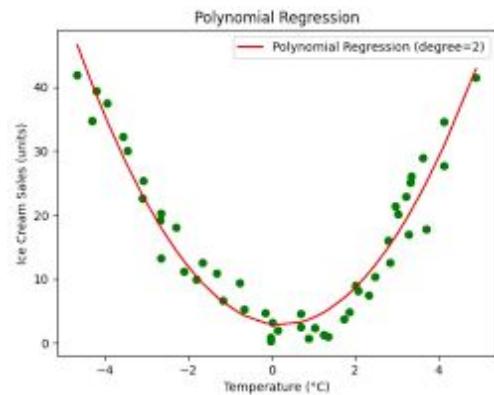
Estimated (or predicted) Y value for observation i
Estimate of the regression intercept
Estimate of the regression slope
Value of X for observation i

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Regresja wielomianowa

- **Model:** krzywa
- **Cel:** to samo

$$y = b_0 + b_1 x_1 + b_2 x_1^2 + \dots + b_n x_1^n$$



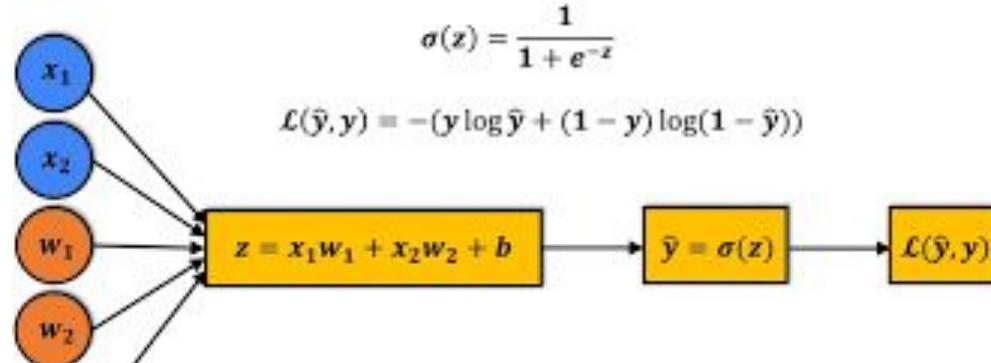
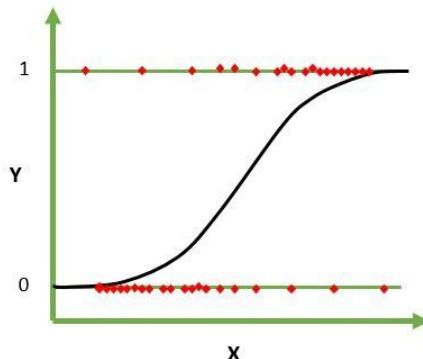
Regresja logistyczna

Model do **klasyfikacji binarnej** (0 / 1)

Funkcja logistyczna (sigmoidalna):

Wynik: prawdopodobieństwo przynależności do klasy

Popularna w detekcji spamu, diagnozie chorób, analizie ryzyka



SVM

Główne do **klasyfikacji**, ale działa też w regresji (SVR)

Szuka **hiperplaszczyzny** maksymalizującej margines między klasami

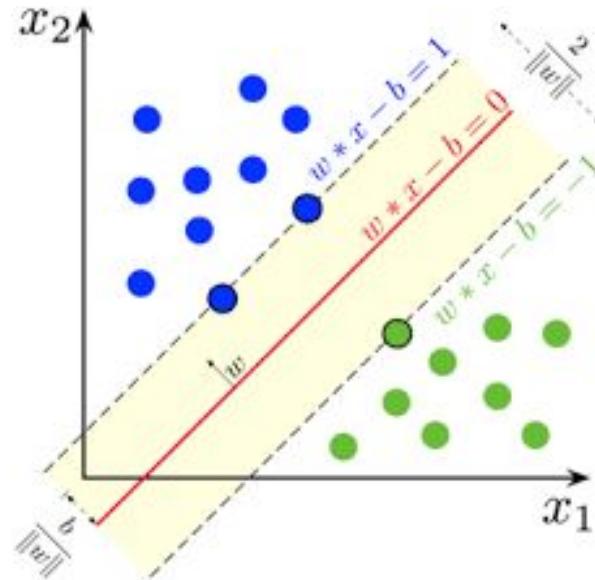
Może używać **jąder** (kernel trick) do klasyfikacji nieliniowej

Dobrze radzi sobie z danymi o dużej liczbie cech

Warunek klasyfikacji

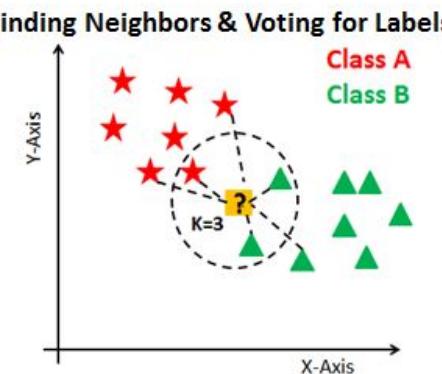
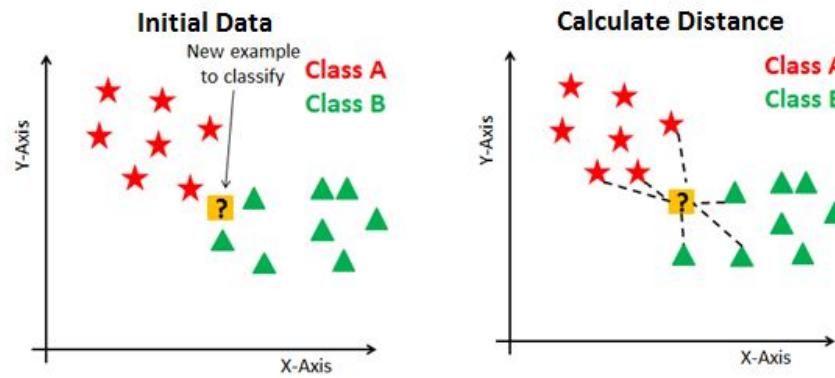
- Klasa +1: $w_1x_1+w_2x_2+b \geq 1$
- Klasa -1: $w_1x_1+w_2x_2+b \leq -1$

$$\text{Margines} = 2 / \|w\|$$

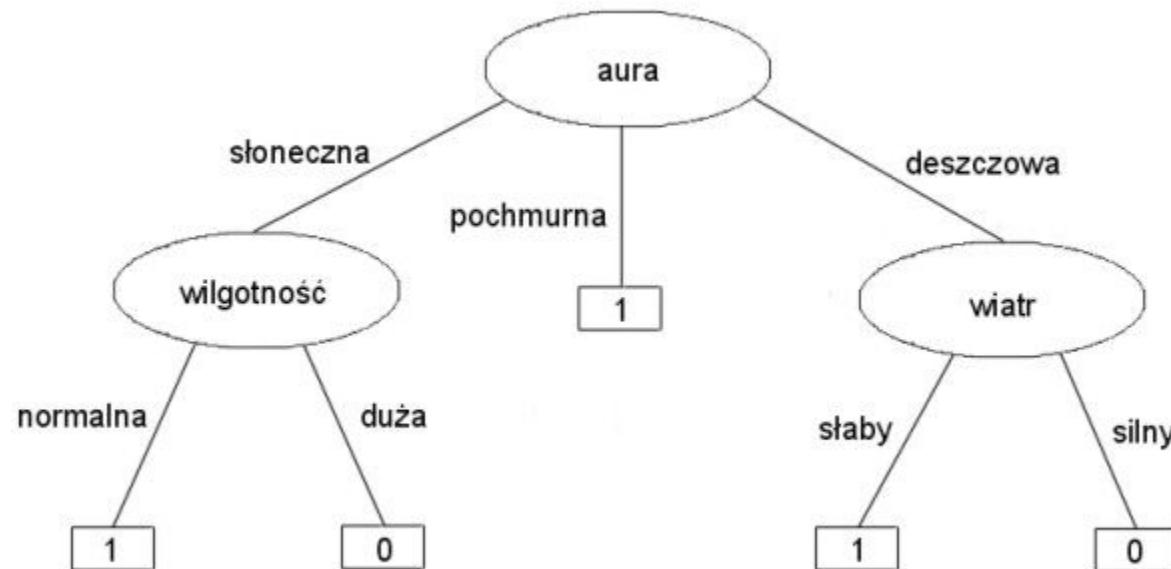


KNN

- **Klasyfikacja** na podstawie k najbliższych punktów
- Brak uczenia modelu – decyzja przy przewidywaniu
- Wymaga definicji **metryki odległości** (np. euklidesowa, kosinusowa)
- Prosty, ale wolny przy dużych zbiorach danych

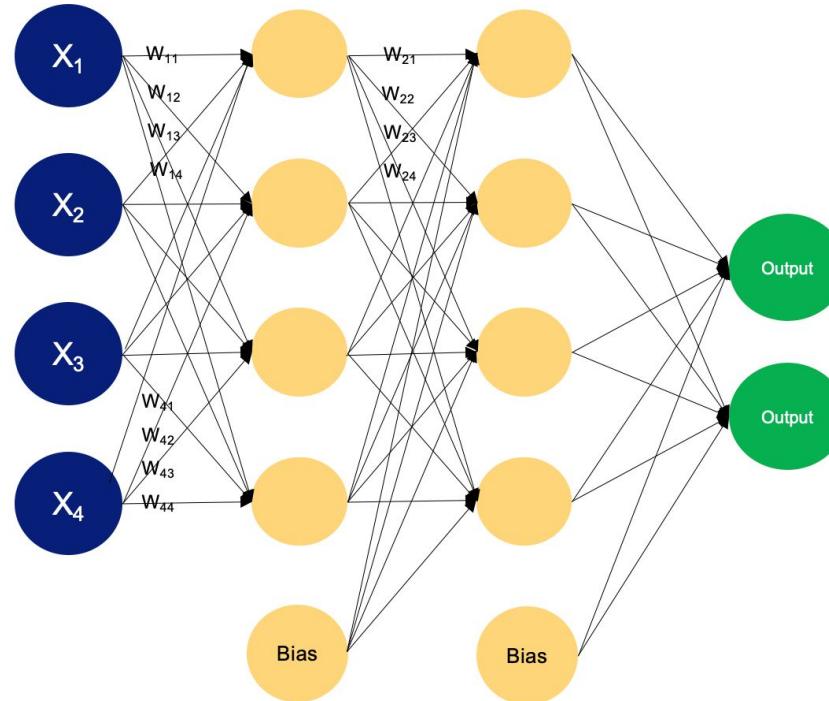


Drzewa



MLP

Inner layer | Hidden layers | Outer layer



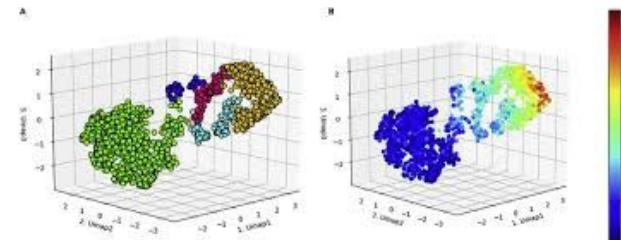
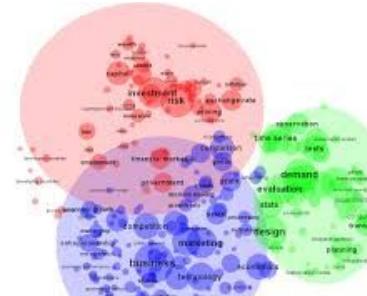
Klasteryzacja

Uczenie **nienadzorowane** – brak etykiet

Celem jest podział danych na **podobne grupy** (klastry)

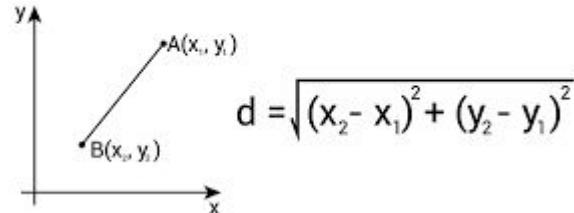
Zastosowania: segmentacja klientów, grupowanie dokumentów, kompresja obrazów

Przykłady algorytmów: KMeans, DBSCAN, GMM



Metryki odległości

Distance Formula



Euklidesowa: „linijka” w przestrzeni

Kosinusowa: porównuje kierunek wektorów

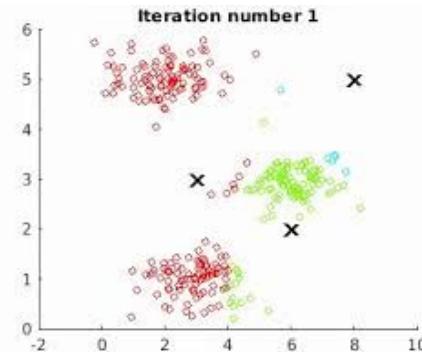
Wybór metryki wpływa na działanie algorytmu

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

K-średnich

Algorytm klasteryzacji:

1. Wybiera **k** centroidów
2. Przypisuje punkty do najbliższego centroidu
3. Aktualizuje położenie centroidów
4. Powtarza, aż centroidy się ustabilizują



Wymaga podania liczby klastrów **k** z góry

Szybki, ale wrażliwy na początkowe ustawienie centroidów

ML workflow

1. Definicja problemu
2. Zebranie i przygotowanie danych
3. Podział na zbiór treningowy / testowy
4. Wybór modelu
5. Trenowanie modelu
6. Ewaluacja (np. accuracy, RMSE)
7. Interpretacja wyników i wdrożenie

Metryki nieklasyfikacji

metryki regresji

Mean Absolute Error
Mean Squared Error
R-squared Score

metryki klasteryzacji

Silhouette Score
Davies-Bouldin Index
Calinski-Harabasz Index

inne metryki

IoU - segmentacja semantyczna, detekcja

https://scikit-learn.org/stable/modules/model_evaluation.html

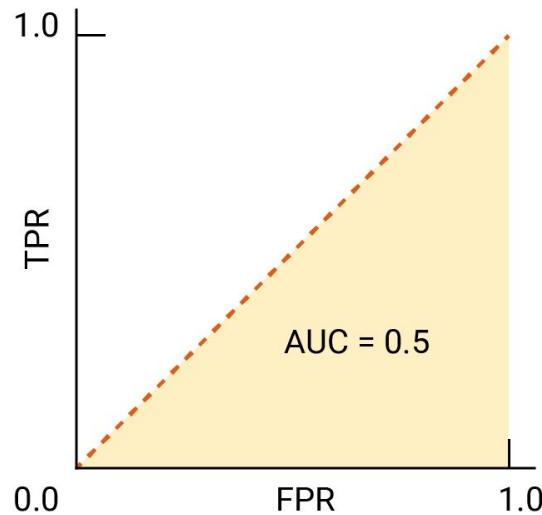
Metryki klasyfikacji

		Predicted	
		Spam	Non-spam
Actual	Spam	600 (True positive)	300 (False negative)
	Non-spam	100 (False positive)	9000 (True negative)

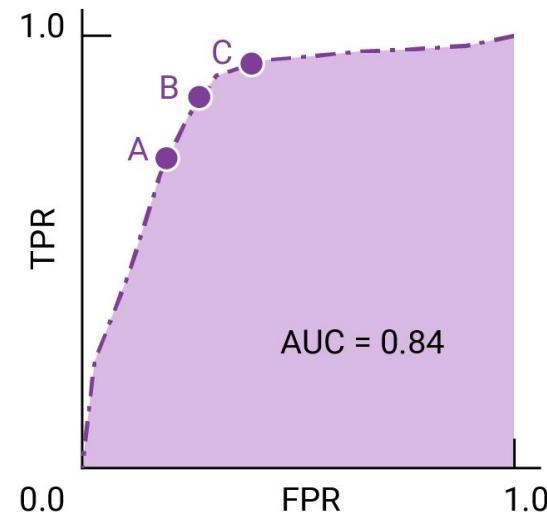
		Predicted condition		Sources: [12][13][14][15][16][17][18][19] view · talk · edit	
		Total population = P + N	Predicted positive	Predicted negative	Informedness, bookmaker informedness (BM) = TPR + TNR - 1
Actual condition	Positive (P) [a]	True positive (TP), hit ^[b]	False negative (FN), miss, underestimation	True positive rate (TPR), recall, sensitivity (SEN), probability of detection, hit rate, power $= \frac{TP}{P} = 1 - FNR$	Prevalence threshold (PT) $= \frac{\sqrt{TPR \times FPR} - FPR}{TPR - FPR}$
	Negative (N) ^[d]	False positive (FP), false alarm, overestimation	True negative (TN), correct rejection ^[e]	False positive rate (FPR), probability of false alarm, fall-out type I error ^[f] $= \frac{FP}{N} = 1 - TNR$	False negative rate (FNR), miss rate type II error ^[c] $= \frac{FN}{P} = 1 - TPR$
Prevalence	$\frac{P}{P+N}$	Positive predictive value (PPV), precision $= \frac{TP}{TP+FP} = 1 - FDR$	Negative predictive value (NPV) $= \frac{TN}{TN+FN} = 1 - FOR$	Positive likelihood ratio (LR+) $= \frac{TPR}{FPR}$	True negative rate (TNR), specificity (SPC), selectivity $= \frac{TN}{N} = 1 - FPR$
Accuracy (ACC)	$\frac{TP+TN}{P+N}$	False discovery rate (FDR) $= \frac{FP}{TP+FP} = 1 - PPV$	False omission rate (FOR) $= \frac{FN}{TN+FN} = 1 - NPV$	Markedness (MK), deltaP ^(ΔP) $= PPV + NPV - 1$	Negative likelihood ratio (LR-) $= \frac{FNR}{TNR}$
Balanced accuracy (BA)	$\frac{TPR + TNR}{2}$	F_1 score $= \frac{2 \cdot PPV \times TPR}{PPV + TPR}$ $= \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$	Fowlkes–Mallows index (FM) $= \sqrt{PPV \times TPR}$	phi or Matthews correlation coefficient (MCC) $= \sqrt{TPR \times TNR \times PPV \times NPV} - \sqrt{FNR \times FPR \times FOR \times DFR}$	Diagnostic odds ratio (DOR) $= \frac{LR+}{LR-}$
					Threat score (TS), critical success index (CSI), Jaccard index $= \frac{TP}{TP + FN + FP}$

https://scikit-learn.org/stable/modules/model_evaluation.html

Metryki klasyfikacji



ROC AUC



https://scikit-learn.org/stable/modules/model_evaluation.html

Metryki klasyfikacji

		Predicted	
		Spam	Non-spam
Actual	Spam	600 (True positive)	300 (False negative)
	Non-spam	100 (False positive)	9000 (True negative)

accuracy - dokładność

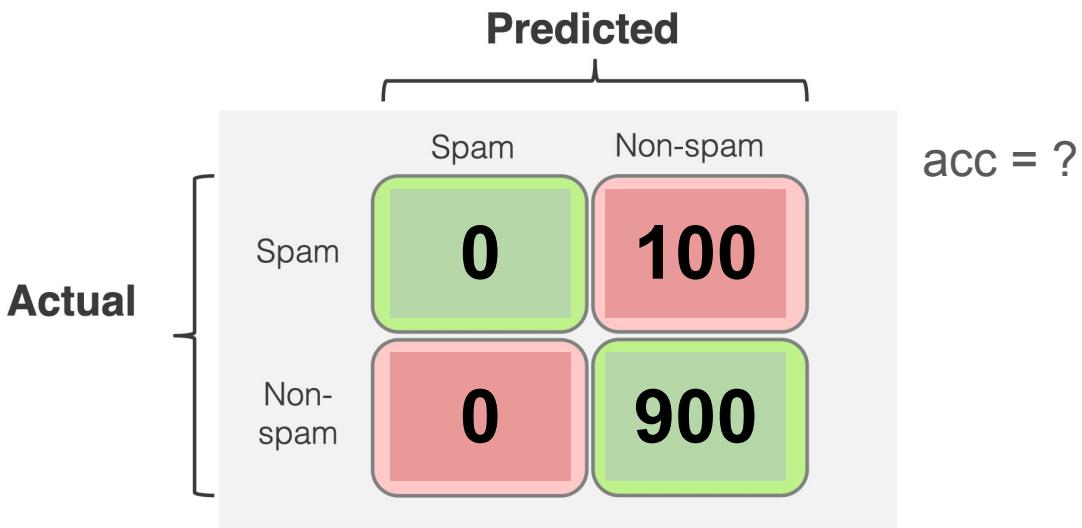
precision - precyza - TP / predykowane pozyt.

recall - czułość - TP / naprawdę pozytywne

f1 score - średnia harmoniczna prec. i recall

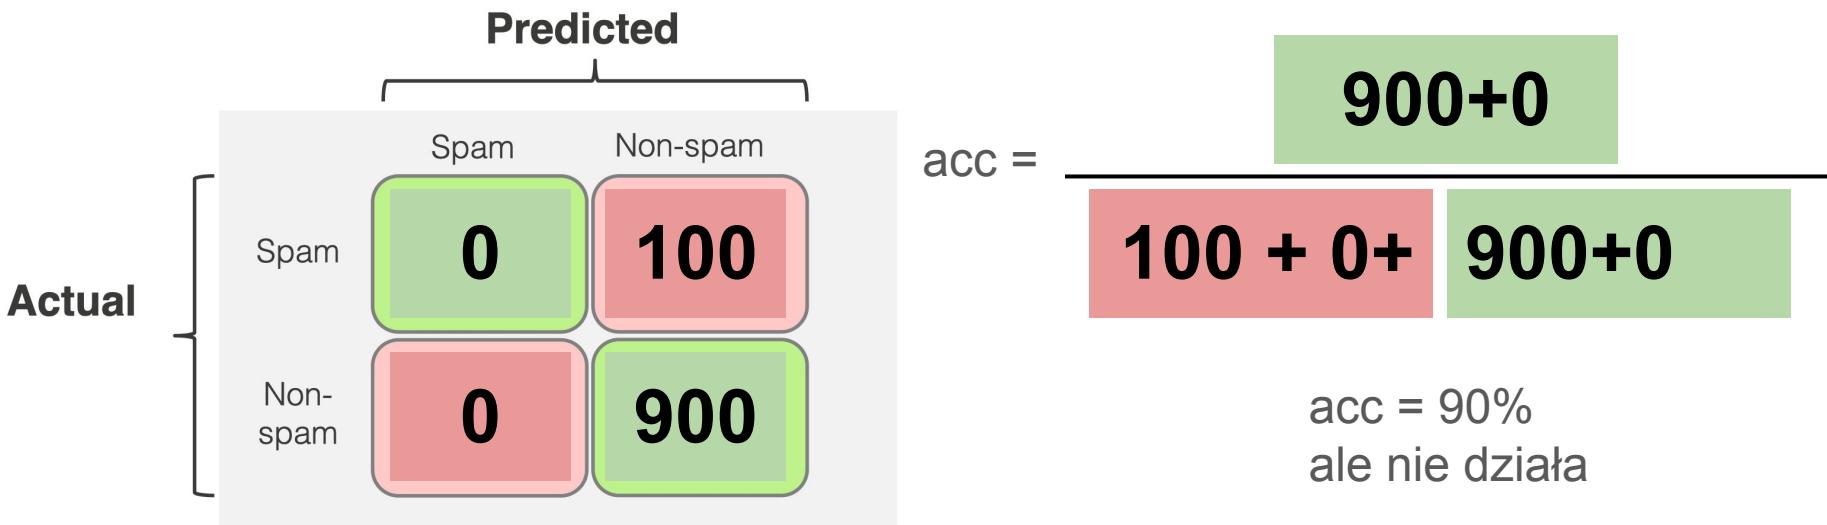
https://scikit-learn.org/stable/modules/model_evaluation.html

Metryki klasyfikacji - dlaczego accuracy jest mylące?



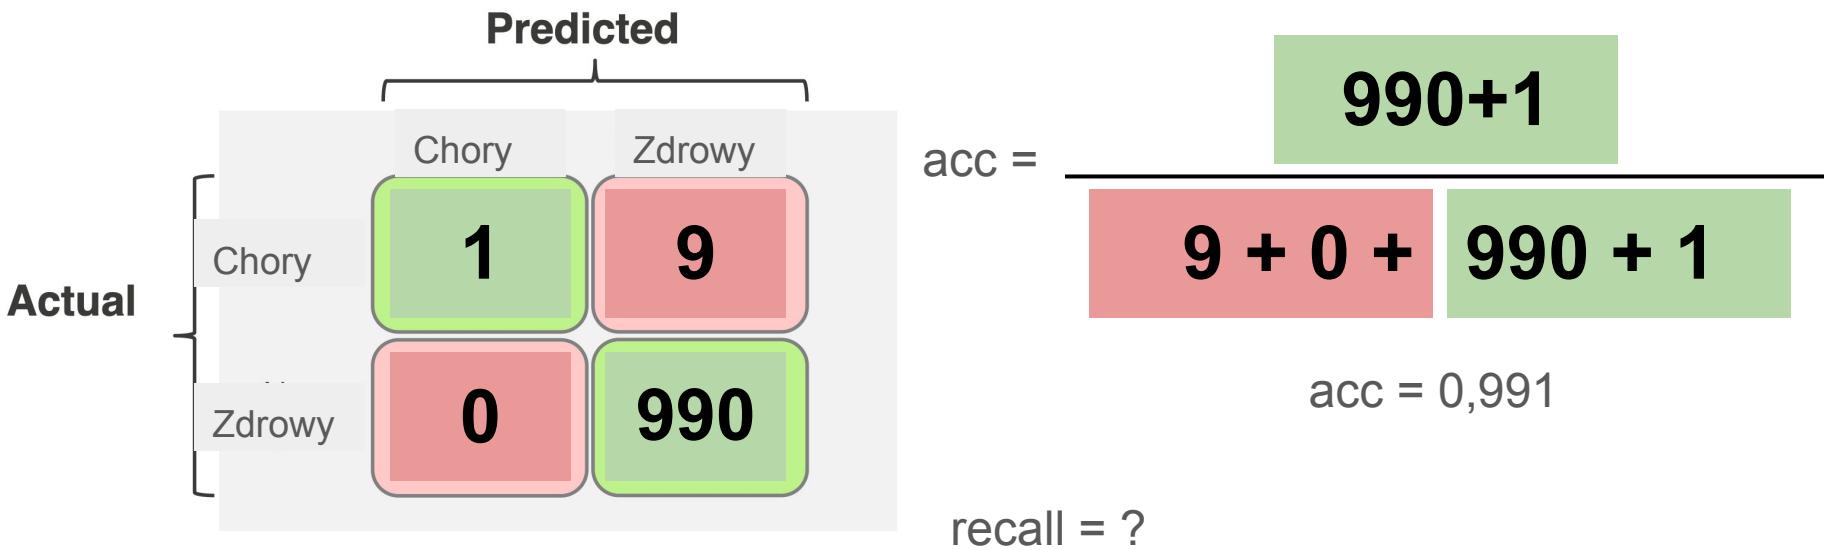
https://scikit-learn.org/stable/modules/model_evaluation.html

Metryki klasyfikacji - dlaczego dokładność jest myląca?



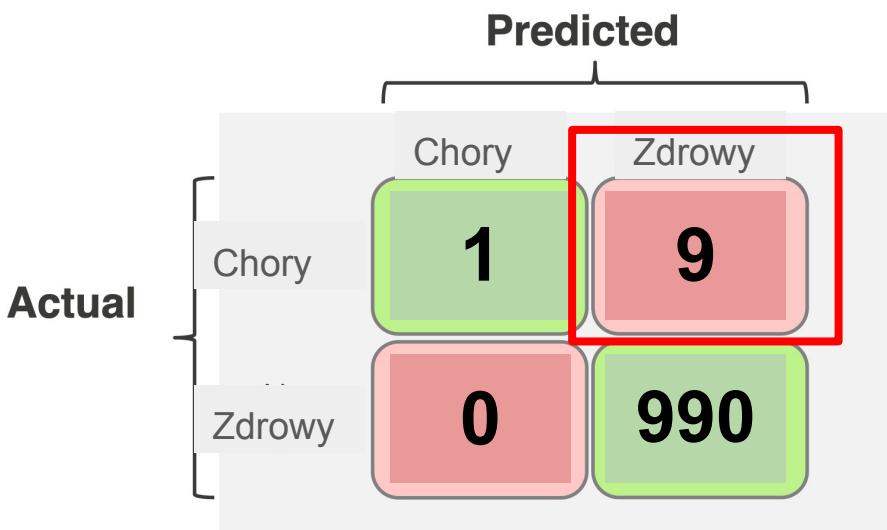
https://scikit-learn.org/stable/modules/model_evaluation.html

Metryki klasyfikacji - dlaczego dokładność jest myląca?



https://scikit-learn.org/stable/modules/model_evaluation.html

Metryki klasyfikacji - dlaczego dokładność jest myląca?



acc = 0,991

recall =

$$\frac{1}{9 + 1} = 0,1$$

https://scikit-learn.org/stable/modules/model_evaluation.html

Metryki klasyfikacji - dlaczego dokładność jest myląca?

		Predicted	
		Spam	Non-spam
Actual	Spam	1	0
	Non-spam	99	900

acc = 0,901

$$\text{precyzja} = \frac{1}{99 + 1} = 0,01$$

https://scikit-learn.org/stable/modules/model_evaluation.html

ML workflow

1. Definicja problemu
2. Zebranie i przygotowanie danych
3. Podział na zbiór treningowy / testowy
4. Wybór modelu
5. Trenowanie modelu
6. Ewaluacja (np. accuracy, RMSE)
7. Interpretacja wyników i wdrożenie

PYTANIA?

Dodatek matematyczny

Rozkłady prawdopodobieństwa

- Opisują **jak rozłożone są wartości** zmiennej losowej
- **Dyskretne** (np. rzut kostką) i **ciągłe** (np. wzrost ludzi)
- W praktyce **rzadko spotykamy idealne rozkłady**
- Służą jako **modele matematyczne** i są wygodne do obliczeń

Rozkład jednostajny

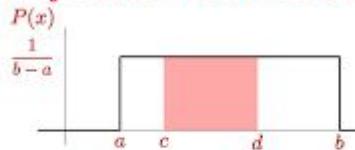
Każdy wynik **jednakowo prawdopodobny**

Przykład: **rzut uczciwą kostką**

Parametry: a (min), b (max)

Gęstość prawdopodobieństwa: stała

Uniform Distribution



$$\text{Mean : } \mu = \frac{a+b}{2} \quad \text{Probability}$$

$$\text{S.D. : } \sigma = \sqrt{\frac{(b-a)^2}{12}} \quad P(c \leq X \leq d) = \frac{d-c}{b-a}$$

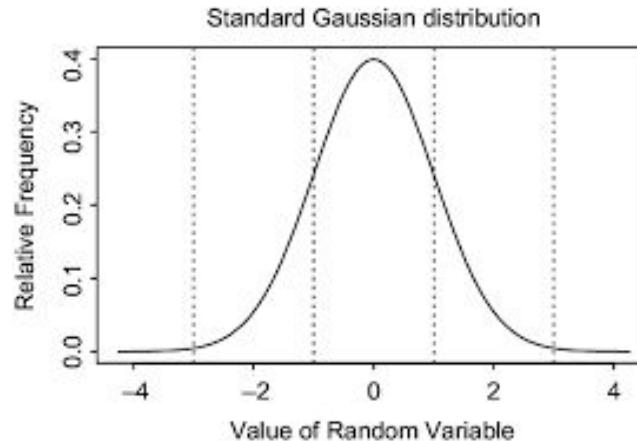
Rozkład normalny (Gaussa)

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Najbardziej znany, „**dzwon**”

Opisywany przez: średnia (μ), odchylenie standardowe (σ)

Przykład: wzrost ludzi, błędy pomiarów



Rozkład wykładniczy

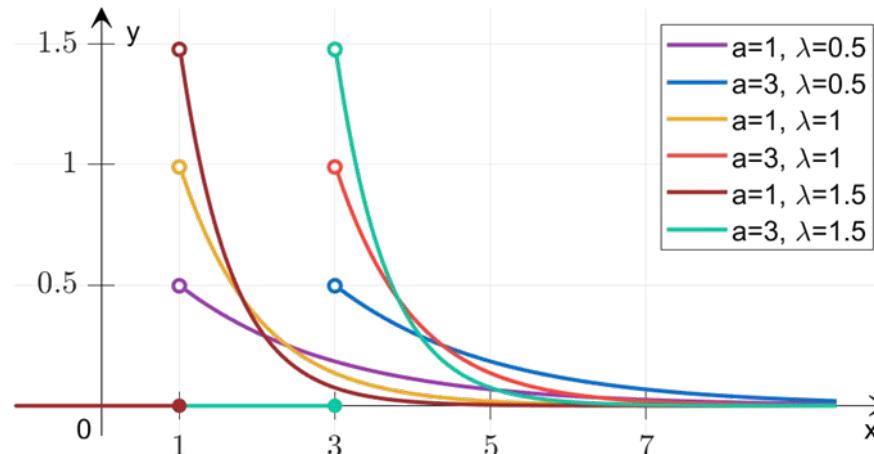
Modeluje **czas oczekiwania** na zdarzenie

Parametr: λ (częstość zdarzeń)

Przykład: czas do nadejścia autobusu (przy losowych odjazdach)

przyszłość nie zależy od przeszłości

$$f(x) = \frac{\lambda^x}{x!} e^{-\lambda}$$



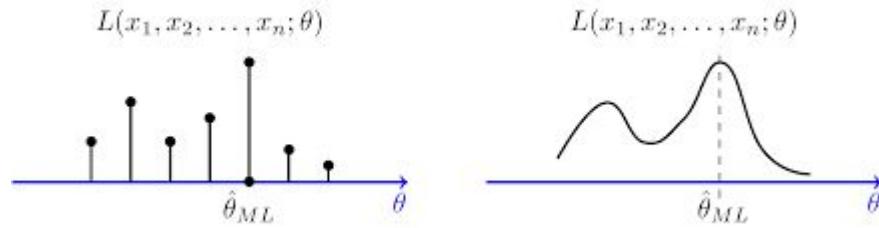
Metoda maksymalnej wiarygodności

Służy do **dopasowania parametrów** modelu do danych

Szukamy parametrów, które **maksymalizują prawdopodobieństwo** zaobserwowania danych

Intuicja: „Jakie parametry sprawiają, że to co widzimy, jest **najbardziej prawdopodobne**?“

Stosowane w regresji, klasyfikacji, statystyce



Metoda maksymalnej wiarygodności

Załóżmy, że mamy niezależne obserwacje (x_1, x_2, \dots, x_n) pochodzące z rozkładu normalnego. Chcemy znaleźć estymatory MLE dla parametrów mu i sigma².

1. Gęstość pojedynczej obserwacji

$$p(x_i | \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

2. Funkcja wiarygodności (likelihood)

$$L(\mu, \sigma) = \prod_{i=1}^n p(x_i | \mu, \sigma) = (2\pi)^{-n/2} \sigma^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

3. Log-wiarygodność

$$\ell(\mu, \sigma) = \log L(\mu, \sigma) = -\frac{n}{2} \log(2\pi) - n \log \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

4. Warunki pierwszego rzędu (pochodne = 0)

- Pochodna względem mu:

$$\frac{\partial \ell}{\partial \mu} = -\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) \stackrel{!}{=} 0 \quad \Rightarrow \quad \sum_{i=1}^n (x_i - \hat{\mu}) = 0$$

stąd

$$\boxed{\hat{\mu}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n x_i}$$

- Pochodna względem sigma:

$$\frac{\partial \ell}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \mu)^2 \stackrel{!}{=} 0.$$

Mnożąc przez (sigma³) i podstawiając mu otrzymujemy

$$-\frac{n\sigma^2}{\sigma} + \sum_{i=1}^n (x_i - \hat{\mu})^2 = 0 \quad \Rightarrow \quad \boxed{\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2}$$

Twierdzenie Bayesa

Startujemy od **przekonania początkowego**

Otrzymujemy **nową obserwację**

Aktualizujemy przekonanie —
prawdopodobieństwo przesuwa się w
stronę hipotezy bardziej wspieranej przez
dane

Przykład: spam/nie-spam, diagnoza chorób,
przewidywanie awarii

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)} \quad (1)$$

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B | A) \cdot P(A) + P(B | \neg A) \cdot P(\neg A)} \quad (2)$$

Regresja liniowa

Cel

Modelowanie zależności liniowej między zmienną niezależną (cechą) a zmienną zależną (wynikiem).

Dane

Mamy obserwacje:

$$\{(x_i, y_i)\}_{i=1}^n, \quad x_i \in \mathbb{R}, \quad y_i \in \mathbb{R}$$

Model

Prosta regresji ma postać:

$$\hat{y} = wx + b$$

gdzie:

- w — współczynnik kierunkowy (nachylenie prostej)
- b — wyraz wolny (przecięcie z osią y)

Funkcja kosztu (MSE)

Chcemy znaleźć w i b , które minimalizują średni błąd kwadratowy:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

Rozwiązywanie analityczne (metoda najmniejszych kwadraturów):

Optymalne parametry można wyliczyć ze wzorów:

$$w = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad b = \bar{y} - w\bar{x}$$

gdzie \bar{x} i \bar{y} to średnie wartości cechy i etykiety.

Interpretacja:

- $w > 0$ oznacza wzrost y wraz ze wzrostem x
- $w < 0$ oznacza spadek y wraz ze wzrostem x

Zastosowanie:

- Predykcja wartości ciągłych
- Analiza wpływu pojedynczej cechy na wynik

SVM

Cel

Znaleźć hiperpłaszczyznę w 2D, która maksymalizuje margines oddzielający dwie klasy.

Dane treningowe

Mamy obserwacje

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^n, \quad \mathbf{x}_i = (x_{i1}, x_{i2}) \in \mathbb{R}^2, \quad y_i \in \{-1, +1\}.$$

Hiperpłaszczyzna decyzyjna

Równanie prostej rozdzielającej:

$$w_1 x_1 + w_2 x_2 + b = 0,$$

gdzie $\mathbf{w} = (w_1, w_2)$ to wektor normalny, a b to offset.

Warunki klasifikacji (margines 1)

Dla każdej próbki wymaga się:

$$y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, n.$$

Margines

Odległość między granicami klas:

$$\text{margines} = \frac{2}{\|\mathbf{w}\|}.$$

Maksymalizacja marginesu \equiv minimalizacja $\frac{1}{2} \|\mathbf{w}\|^2$.

Problem optymalizacyjny (prymalny)

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{pod warunkiem} \quad y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 \quad \forall i.$$

Funkcja Lagrange'a

Wprowadzamy mnożniki $\alpha_i \geq 0$ i definiujemy:

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i [y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1].$$

Problem dualny

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j)$$

przy ograniczeniach

$$\sum_{i=1}^n \alpha_i y_i = 0, \quad \alpha_i \geq 0 \quad \forall i.$$

Support vectors

Próbki z $\alpha_i > 0$ to support vectors — to one definiują granicę.

K-średnich

Cel

Podział zbioru danych na k skupień (klastrów), tak aby punkty w jednym klastrze były jak najbardziej do siebie podobne.

Dane

Mamy zbiór punktów:

$$\{\mathbf{x}_i\}_{i=1}^n, \quad \mathbf{x}_i \in \mathbb{R}^d$$

Działanie algorytmu:

1. Inicjalizacja — wybierz losowo k centroidów (środków klastrów):

$$\{\boldsymbol{\mu}_j^{(0)}\}_{j=1}^k$$

2. Przypisanie punktów do klastrów:

Każdy punkt przypisz do najbliższego centroidu:

$$C_j^{(t)} = \left\{ \mathbf{x}_i : \|\mathbf{x}_i - \boldsymbol{\mu}_j^{(t)}\|^2 \leq \|\mathbf{x}_i - \boldsymbol{\mu}_l^{(t)}\|^2, \forall l = 1, \dots, k \right\}$$

3. Aktualizacja centroidów:

Dla każdego klastra oblicz nowy centroid jako średnią punktów w klastrze:

$$\boldsymbol{\mu}_j^{(t+1)} = \frac{1}{|C_j^{(t)}|} \sum_{\mathbf{x}_i \in C_j^{(t)}} \mathbf{x}_i$$

4. Powtarzaj kroki 2 i 3 aż do zbieżności (np. centroidy przestaną się zmieniać).

Funkcja celu (minimalizacja wewnętrzkklastrowej sumy kwadratów odległości):

$$J = \sum_{j=1}^k \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2$$

Algorytm stara się minimalizować J .

Uwagi:

- Algorytm jest czuły na wybór początkowych centroidów.
- Działa najlepiej, gdy klastry są kuliste i mają podobną wielkość.
- Stosowany w eksploracji danych i segmentacji.